Задача про систему контроля версий

Юрий Литвинов
yurii.litvinov@gmail.com

02.03.2017г

Double-checked locking

Вот так неправильно:

```
private T value;

T get() {
    if (value == NONE) {
        synchronized (this) {
            if (value == NONE) {
                value = supplier.get();
            }
        }
    }
    return value;
}
```

Double-checked locking

Вот так правильно (начиная с Java 5):

```
private volatile T value;

T get() {
    if (value == NONE) {
        synchronized (this) {
            if (value == NONE) {
                value = supplier.get();
            }
        }
    }
    return value;
}
```

Double-checked locking

Или даже так:

```
private volatile T value;

T get() {
    T result = value;
    if (result == NONE) {
        synchronized (this) {
            result = value;
            if (result == NONE) {
                result = value = supplier.get();
            }
        }
    }
    return result;
}
```

Lock-free

```
T get() {
    if (value == NONE) {
        Supplier<T> local = supplier;
        if (local != null) {
            if (updater.compareAndSet(this, NONE, local.get())) {
                supplier = null;
            }
        }
    }
    return value;
}}
```

Немного про внутреннее устройство Git[1]

Структура папки .git:

- HEAD
- index
- config
- description
- hooks/
- info/
- objects/
- refs/
- ...

[1] По гл. 10 https://git-scm.com/book и http://aosabook.org/en/git.html

Объекты

Git внутри — хеш-таблица, отображающая SHA-1-хеш файла в содержимое файла. Пример:

```
$ git init test
Initialized empty Git repository in /tmp/test/.git/
$ cd test
$ find .git/objects
.git/objects
.git/objects/info
.git/objects/pack

$ echo 'test content' | git hash-object -w --stdin
d670460b4b4aece5915caf5c68d12f560a9fe3e4

$ find .git/objects -type f
.git/objects/d6/70460b4b4aece5915caf5c68d12f560a9fe3e4
```

Объекты (2)

Как получить сохранённый объект:

```
$ git cat-file -p d670460b4b4aece5915caf5c68d12f560a9fe3e4
test content
```

Версионный контроль:

```
$ echo 'version 1' > test.txt
$ git hash-object -w test.txt
83baae61804e65cc73a7201a7252750c76066a30
$ echo 'version 2' > test.txt
$ git hash-object -w test.txt
1f7a7a472abf3dd9643fd615f6da379c4acb3e3a
$ find .git/objects -type f
.git/objects/1f/7a7a472abf3dd9643fd615f6da379c4acb3e3a
.git/objects/83/baae61804e65cc73a7201a7252750c76066a30
.git/objects/d6/70460b4b4aece5915caf5c68d12f560a9fe3e4
```

Объекты (3)

Переключение между версиями файла:

```
$ git cat-file -p 83baae61804e65cc73a7201a7252750c76066a30 \
    > test.txt
$ cat test.txt
version 1

$ git cat-file -p 1f7a7a472abf3dd9643fd615f6da379c4acb3e3a \
    > test.txt
$ cat test.txt
version 2
```

Деревья

blob (то, что мы видели раньше) хранит только содержимое файла, не хранит даже его имя. Решение проблемы — tree:

```
$ git cat-file -p master^{tree}
100644 blob a906cb2a4a904a152e80877d4088654daad0c859     README
100644 blob 8f94139338f9404f26296befa88755fc2598c289     Rakefile
040000 tree 99f1a6d12cb4b6f19c8655fca46c3ecf317074e0     lib
```

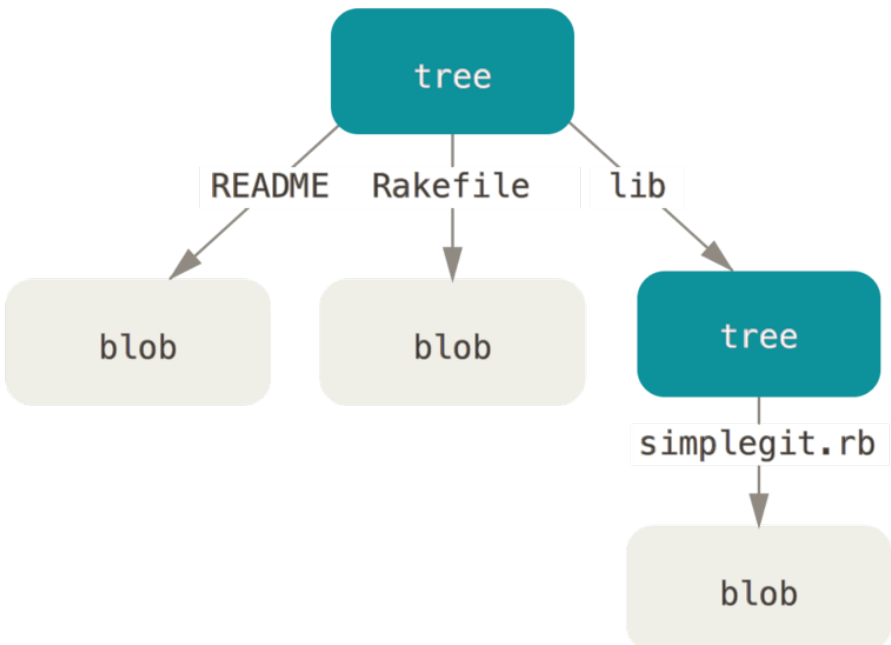

Какие ещё виды объектов бывают

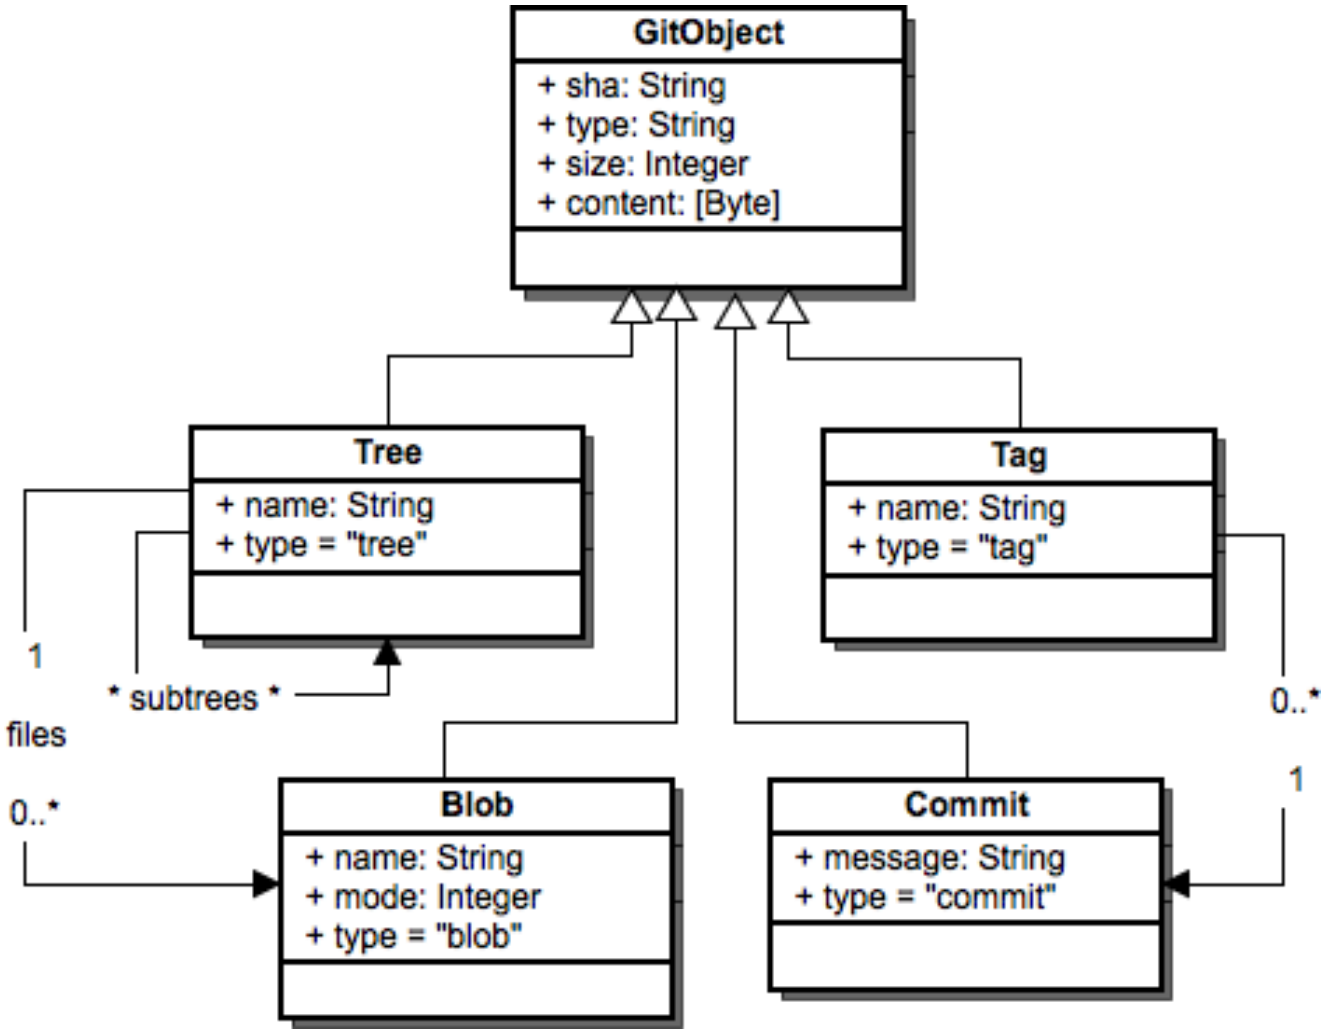

Коммиты

tree-объекты могут хранить структуру файлов (как inode в файловой системе), но не хранят метаинформацию типа автора файла и даты создания. Это хранится в commit-объектах:

```
$ echo 'first commit' | git commit-tree d8329f
fdf4fc3344e67ab068f836878b6c4951e3b15f3d

$ git cat-file -p fdf4fc3
tree d8329fc1cc938780ffdd9f94e0d364e0ea74f579
author Scott Chacon <schacon@gmail.com> 1243040974 -0700
committer Scott Chacon <schacon@gmail.com> 1243040974 -0700

first commit
```

Ещё коммит хранит список коммитов-родителей

Коммиты, как это выглядит

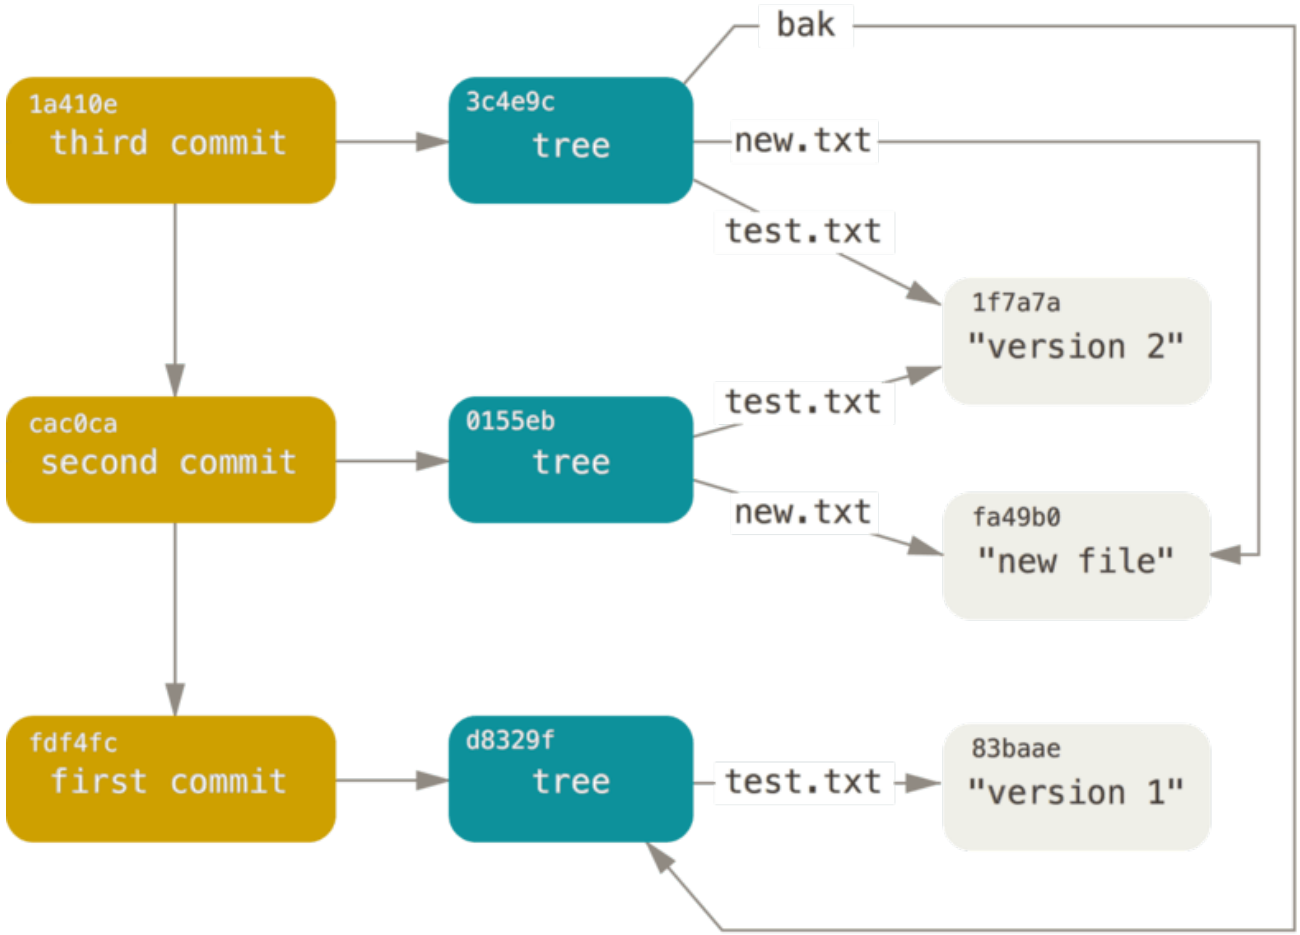

Ссылки

Теперь вся информация хранится на диске, но чтобы ей воспользоваться, нужно помнить SHA-1 хеши. На помощь приходят reference-ы.

- .git/refs
- .git/refs/heads
- .git/refs/tags

```
$ echo "1a410efbd13591db07496601ebc7a059dd55cfe9" \
  > .git/refs/heads/master
```

```
$ git log --pretty=oneline master
1a410efbd13591db07496601ebc7a059dd55cfe9 third commit
cac0cab538b970a37ea1e769cbbde608743bc96d second commit
fdf4fc3344e67ab068f836878b6c4951e3b15f3d first commit
```

- Команда git update-ref

Ссылки, как это выглядит

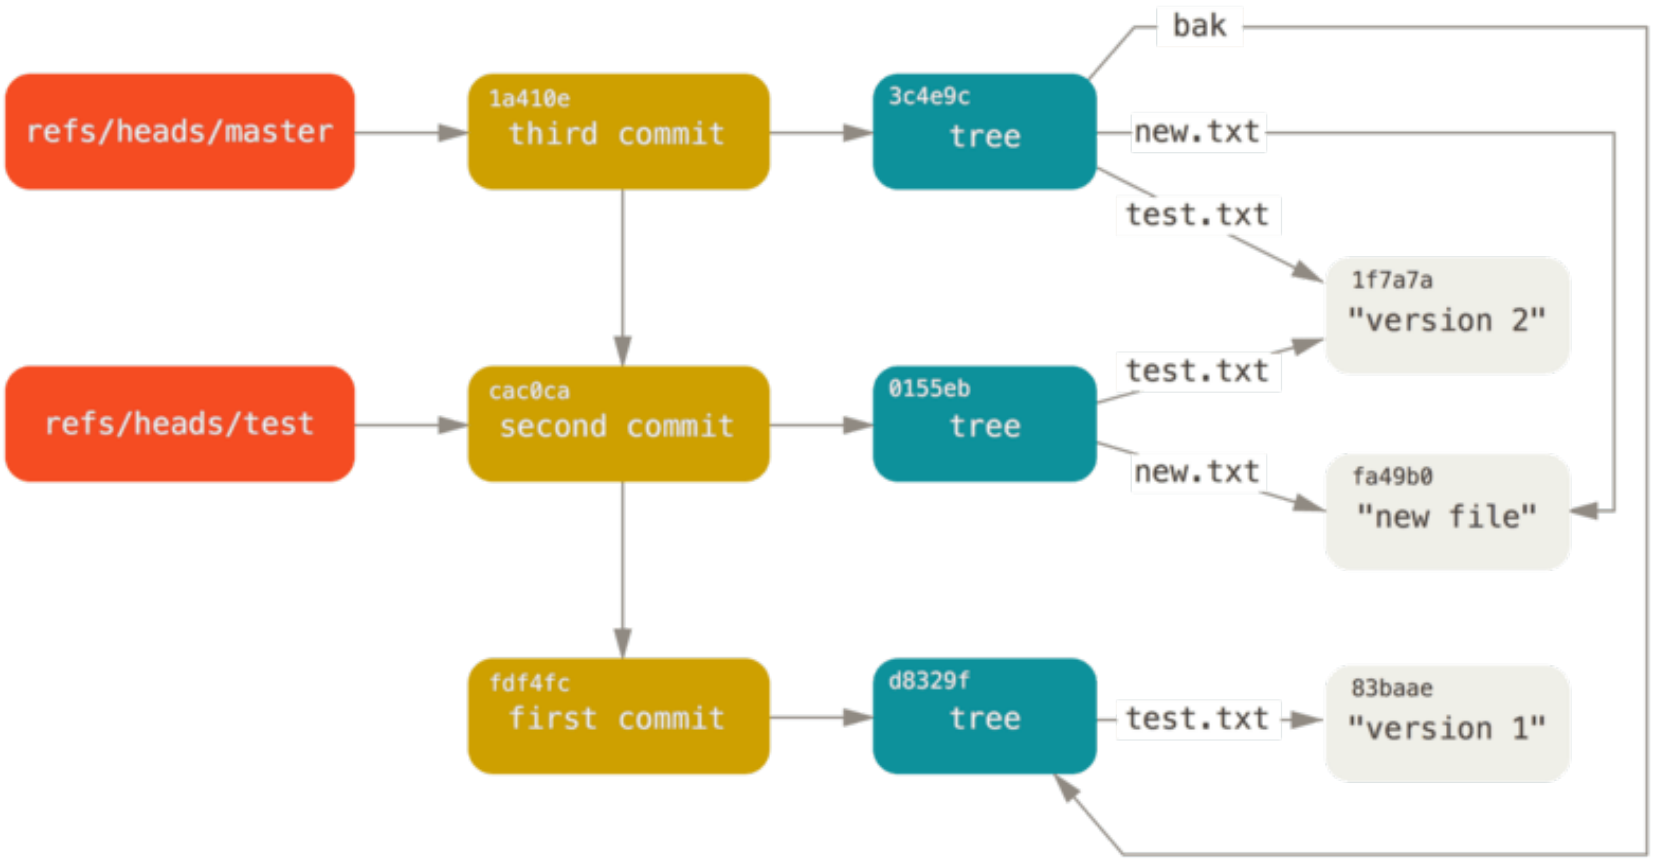

HEAD

Теперь не надо помнить хеши, но как переключаться между ветками?
Текущая ветка хранится в HEAD. HEAD — символическая ссылка, то есть ссылка на другую ссылку.

```
$ cat .git/HEAD
ref: refs/heads/master

$ git symbolic-ref HEAD refs/heads/test
$ cat .git/HEAD
ref: refs/heads/test
```

Тэги

Последний из объектов в Git — tag. Это просто указатель на коммит.

- Легковесный тэг:

  git update-ref refs/tags/v1.0 cac0cab538b970a37ea1e769cbbde608743bc96d

  Или просто git tag

- Аннотированный тэг:

  $ git tag -a v1.1 1a410efbd13591db07496601ebc7a059dd55cfe9 -m 'test tag'

  $ git cat-file -p 9585191f37f7b0fb9444f35a9bf50de191beadc2
  object 1a410efbd13591db07496601ebc7a059dd55cfe9
  type commit
  tag v1.1
  tagger Scott Chacon <schacon@gmail.com> Sat May 23 16:48:58 2009 -0700

  test tag

Packfiles

Пока что получалось, что все версии всех файлов в Git хранятся целиком, как они есть. Все они всегда сжимаются zlib, но в целом, если создать репозиторий, добавлять туда файлы, коммитить и т.д., все версии всех файлов будут в нём целиком. На помощь приходят .pack-файлы:

```
$ git gc
Counting objects: 18, done.
Delta compression using up to 8 threads.
Compressing objects: 100% (14/14), done.
Writing objects: 100% (18/18), done.
Total 18 (delta 3), reused 0 (delta 0)

$ find .git/objects -type f
.git/objects/bd/9dbf5aae1a3862dd1526723246b20206e5fc37
.git/objects/d6/70460b4b4aece5915caf5c68d12f560a9fe3e4
.git/objects/info/packs
.git/objects/pack/pack-978e03944f5c581011e6998cd0e9e30000905586.idx
.git/objects/pack/pack-978e03944f5c581011e6998cd0e9e30000905586.pack
```

Как оно устроено

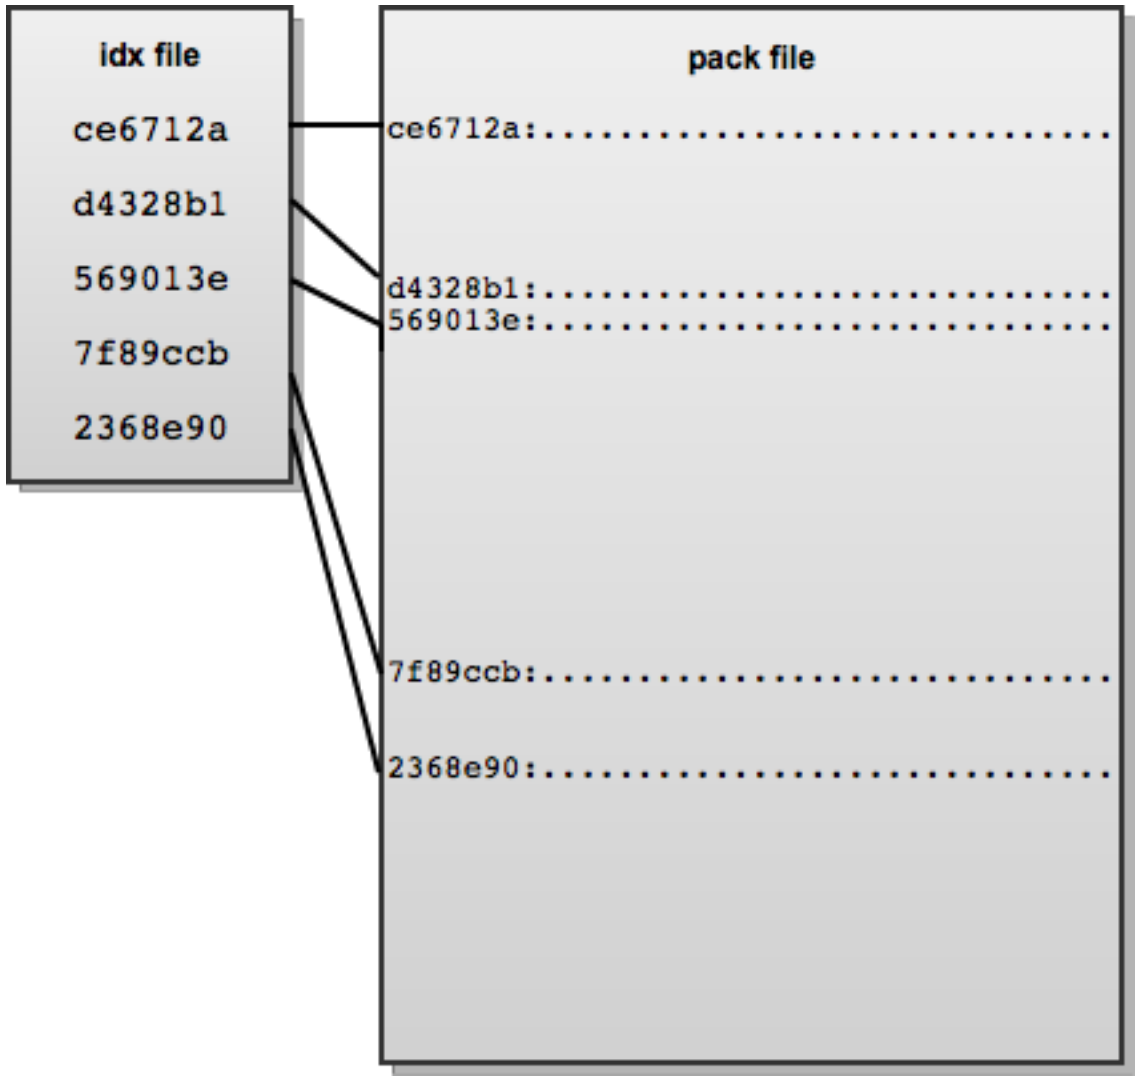

Pack-файлы, подробности

- Упаковка происходит, когда:
  - Выполняется git push
  - Слишком много «свободных» объектов (порядка 7000)
  - Вручную вызвана git gc
- Используется дельта-компрессия
  - Последняя версия хранится целиком, дельты «идут назад»
- Можно заглянуть внутрь, git verify-pack
- Git может хитро перепаковывать pack-файлы

Reflog и восстановление коммитов

```
$ git reflog
1a410ef HEAD@{0}: reset: moving to 1a410ef
ab1afef HEAD@{1}: commit: modified repo.rb a bit
484a592 HEAD@{2}: commit: added repo.rb

$ git log -g
commit 1a410efbd13591db07496601ebc7a059dd55cfe9
Reflog: HEAD@{0} (Scott Chacon <schacon@gmail.com>)
Reflog message: updating HEAD
Author: Scott Chacon <schacon@gmail.com>
Date:   Fri May 22 18:22:37 2009 -0700

    third commit
$ git branch recover-branch ab1afef
```

Как более капитально прострелить себе ногу

И что делать

```
$ git branch -D recover-branch
$ rm -Rf .git/logs/

$ git fsck --full
Checking object directories: 100% (256/256), done.
Checking objects: 100% (18/18), done.
dangling blob d670460b4b4aece5915caf5c68d12f560a9fe3e4
dangling commit ab1afef80fac8e34258ff41fc1b867c702daa24b
dangling tree aea790b9a58f6cf6f2804eeac9f0abbe9631e4c9
dangling blob 7108f7ecb345ee9d0084193f147cdad4d2998293
```

Git не удалит даже «висячие» объекты несколько месяцев, если его явно не попросить.

Условие задачи

Своя локальная система контроля версий

Требуется сделать систему контроля версий, представляющую из себя консольное приложение и умеющую:

- commit с commit message (сообщение обязательно и принимается как параметр, система должна сама добавлять ещё дату коммита и автора)
- работу с ветками: создание и удаление
- checkout по имени ревизии или ветки
- log — список ревизий вместе с commit message в текущей ветке
- merge — сливает указанную ветку с текущей
  - конфликты разрешайте (или не разрешайте) любым разумным способом

Нефункциональные требования

- Документация: комментарии, помощь для пользователя, краткое описание внутреннего устройства
- Тесты
- Исключения, обработка ошибок
- Вывод в консоль — только в клиентском коде типа main(), основной код должен позволять себя использовать как библиотеку
- Развитый программный интерфейс, должно быть можно без проблем потом прикрутить GUI
- Аннотации @NotNull, @Nullable/Optional
- Continuous Integration

Примечания

- Не накладывается никаких ограничений на хранимые на диске данные и их формат
  - Дельта-компрессию делать не надо
- Не требуется работа с удалёнными репозиториями
- Дедлайн: до 23:59 22.03