Внутреннее представление данных

Юрий Литвинов
yurii.litvinov@gmail.com

05.10.2018

Побитовые операции

- & — побитовое “И”
- | — побитовое “ИЛИ”
- $\sim$ — побитовое “НЕ”
- 1 & 2 == false, но 1 && 2 == true
- $<<$, $>>$ — битовый сдвиг
  - int x = 1 $<<$ 3
- sizeof — размер типа в байтах
  - int s = sizeof(int) * 8
- Обратите внимание, что ВСЁ хранится как набор бит
  - “3” — литерал, лишь удобная форма записи 00...0011 в коде

Маски

&:

1	1	0	1	1	0	1	0
0	0	0	0	0	0	0	1
0	0	0	0	0	0	0	0

&:

1	1	0	1	1	0	1	0
0	0	0	0	0	0	1	0
0	0	0	0	0	0	1	0

Работа с масками

```
char x = 5;

int bit = 0b10000000;
for (int j = 0; j < 8; ++j)
{
    printf((x & bit) ? "1" : "0");
    bit = bit >> 1;
}
```

Целые числа

- Прямой код
  - 5 — 00000101, -5 — 10000101
- Обратный код
  - 5 — 00000101, -5 — 11111010
- Дополнительный код
  - 5 — 00000101, -5 — 11111011
  - $-x$ представляется как $2^n - x$, поэтому и дополнительный
    - n — разрядность регистра

Арифметические действия

- В обратном коде единица переноса в старшем разряде прибавляется к младшему разряду
- В дополнительном коде единица переноса в старшем разряде отбрасывается

Формат записи

- Литералы
  - `int hexadecimal = 0x35FF;`
  - `int octal = 03567;`
  - `int binary = 0b00100111;` (C++14, может не работать)
  - `0xFF == 255`
- ```
  int x = 239;
  unsigned char *b = reinterpret_cast<unsigned char*>(&x);
  printf("0x%02X%02X%02X%02X\n", b[0], b[1], b[2], b[3]);
  ```

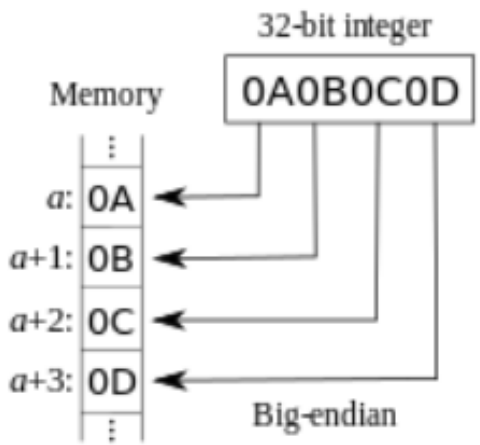

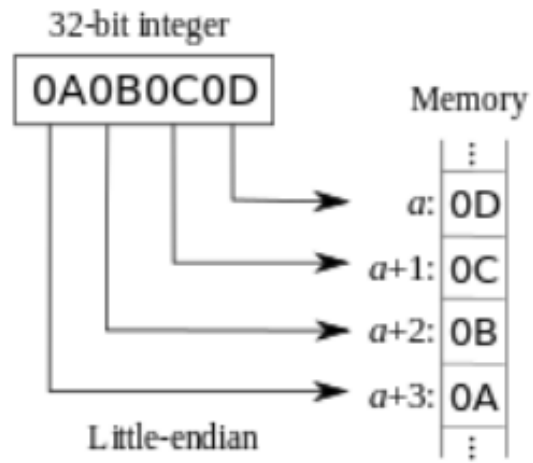
  ```

Вещественные числа

- IEEE 754 — международный стандарт
- $x = (+-)m * p^q$
  - p — основание системы счисления
  - q — порядок числа (целое число)
  - m — мантисса числа (правильная p-ичная дробь, у которой первая цифра после запятой не равна 0)
    - Часто используют нормализованную запись, $m \in [1, p)$
  - Например:
    - $3,1415926 = 0,31415926 * 10^1$
    - $1000 = 0,1 * 10^4$
    - $0,123456789 = 0,123456789 * 10^0$
    - $0,0000107_8 = 0,107_8 * 8^{-4}$
    - $1000,0001_2 = 0,10000001_2 * 2^4$
    - $0 = 0,0 * 10^0$

Внутреннее представление

- 123.456
- Наиболее точное представление (IEEE 754 Double, 64 бит): $1.2345600000000000306954461848 4E2$

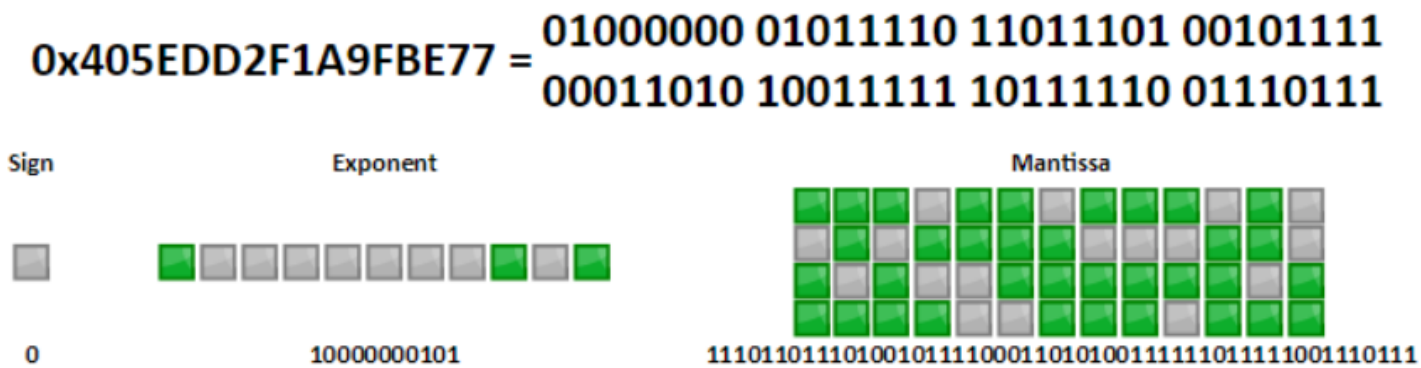

- http://www.binaryconvert.com/

Смещённый порядок

- $123.456 : q = 10000000101_2???$
- Смещённый порядок = $2^{a-1} - 1$ + <истинный порядок>
  - a — количество разрядов, отводимых под порядок
  - Чтобы не хранить знак ещё и порядка числа
- $123.456 \approx 1111011.01110100101111 = 1.11101101110100101111 * 2^6$
- Смещённый порядок = $2^{10} - 1 + 6 = 1029_{10} = 10000000101_2$

Специальные числа

- Неопределённость (NaN):

- Бесконечности:


```
double y = 0.0;
double x = 239.0 / y;
std::cout << x;
```

Строки

Строка как последовательность символов (их кодов) — таблица символов

- ASCII (American Standard Code for Information Interchange)
  - 8 бит на символ (0 – 255), 0 – 127 стандартны, 128 – 255 — для локальных алфавитов
  - Кодовые страницы
    - cp866
    - cp1251
    - koi8-r
    - ...
- Unicode

Строка как последовательность байт — кодировка

- UCS-16BE, UCS16-LE, UTF-8

Зачем

- Локализация — перевод программы на другой язык (и под другую культуру)
- Интернационализация — сделать так, чтобы программу было можно локализовать
- У однобайтовых кодировок некоторые проблемы с иероглифическими языками
  - Shift JIS и прочие странные вещи

Юникод

- UCS, universal character set
  - Кодовые позиции — целые числа (U+0000 – U+007F, ...)
  - Порядка 110 000 кодовых позиций
- UTF, Unicode transformation format
  - Кодировки — битовое представление кодов из UCS
- UTF-8
  - 0x00000000 – 0x0000007F: 0xxxxxxx
  - 0x00000080 – 0x000007FF: 110xxxxx 10xxxxxx
  - 0x00000800 – 0x0000FFFF: 1110xxxx 10xxxxxx 10xxxxxx
  - 0x00010000 – 0x001FFFFF: 11110xxx 10xxxxxx 10xxxxxx 10xxxxxx
  - В точности совпадает с ASCII для первых 127 символов
- BOM (Byte Order Mark)
  - FE FF, FF FE, EF BB BF