

Практика 10: Примеры архитектур

Юрий Литвинов
y.litvinov@spbu.ru

08.11.2022

Краткая история систем контроля версий

- ▶ 1975 – SCCS (Source Code Control System)
 - ▶ Дельты
- ▶ 1982 – RCS (Revision Control System)
 - ▶ С открытым исходным кодом (до сих пор поддерживается GNU)
- ▶ 1986 – CVS (Concurrent Versioning System)
 - ▶ Одновременное редактирование, мерджи, ветки, тэги, удалённые репозитории
- ▶ 2000 – SVN (Subversion)
- ▶ 2005 — Git, Mercurial, Bazaar
 - ▶ Распределённые

- ▶ Распределённая VCS
- ▶ Linus Torvalds, 2005 год, драма с BitKeeper
- ▶ Architectural drivers
 - ▶ Распределённая разработка с тысячей коммитеров
 - ▶ Защита от порчи исходников
 - ▶ Возможность отменить мердж, смерджиться вручную
 - ▶ Высокая скорость работы

¹ По гл. 10 <https://git-scm.com/book> и <http://aosabook.org/en/git.html>

Внутреннее устройство Git

Структура папки .git:

- ▶ HEAD
- ▶ index
- ▶ config
- ▶ description
- ▶ hooks/
- ▶ info/
- ▶ objects/
- ▶ refs/
- ▶ ...

Объекты

Git внутри — хеш-таблица, отображающая SHA-1-хеш файла в содержимое файла. Пример:

```
$ git init test
```

```
Initialized empty Git repository in /tmp/test/.git/
```

```
$ cd test
```

```
$ find .git/objects
```

```
.git/objects
```

```
.git/objects/info
```

```
.git/objects/pack
```

```
$ echo 'test content' | git hash-object -w --stdin  
d670460b4b4aece5915caf5c68d12f560a9fe3e4
```

```
$ find .git/objects -type f
```

```
.git/objects/d6/70460b4b4aece5915caf5c68d12f560a9fe3e4
```

Объекты (2)

Как получить сохранённый объект:

```
$ git cat-file -p d670460b4b4aece5915caf5c68d12f560a9fe3e4  
test content
```

Версионный контроль:

```
$ echo 'version 1' > test.txt  
$ git hash-object -w test.txt  
83baae61804e65cc73a7201a7252750c76066a30  
$ echo 'version 2' > test.txt  
$ git hash-object -w test.txt  
1f7a7a472abf3dd9643fd615f6da379c4acb3e3a  
$ find .git/objects -type f  
.git/objects/1f/7a7a472abf3dd9643fd615f6da379c4acb3e3a  
.git/objects/83/baae61804e65cc73a7201a7252750c76066a30  
.git/objects/d6/70460b4b4aece5915caf5c68d12f560a9fe3e4
```

Объекты (3)

Переключение между версиями файла:

```
$ git cat-file -p 83baae61804e65cc73a7201a7252750c76066a30 \  
> test.txt  
$ cat test.txt  
version 1
```

```
$ git cat-file -p 1f7a7a472abf3dd9643fd615f6da379c4acb3e3a \  
> test.txt  
$ cat test.txt  
version 2
```

Деревья

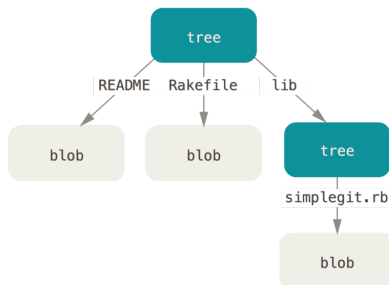
blob (то, что мы видели раньше) хранит только содержимое файла, не хранит даже его имя. Решение проблемы — tree:

```
$ git cat-file -p master^{tree}
```

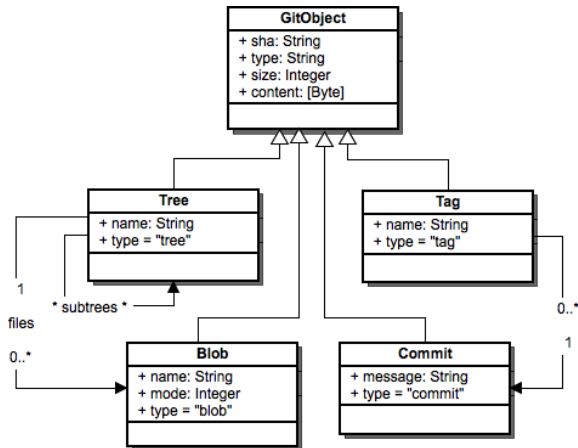
```
100644 blob a906cb2a4a904a152e80877d4088654daad0c859    README
```

```
100644 blob 8f94139338f9404f26296befa88755fc2598c289    Rakefile
```

```
040000 tree 99f1a6d12cb4b6f19c8655fca46c3ecf317074e0    lib
```



Какие ещё виды объектов бывают



Коммиты

tree-объекты могут хранить структуру файлов (как inode в файловой системе), но не хранят метаинформацию типа автора файла и даты создания. Это хранится в commit-объектах:

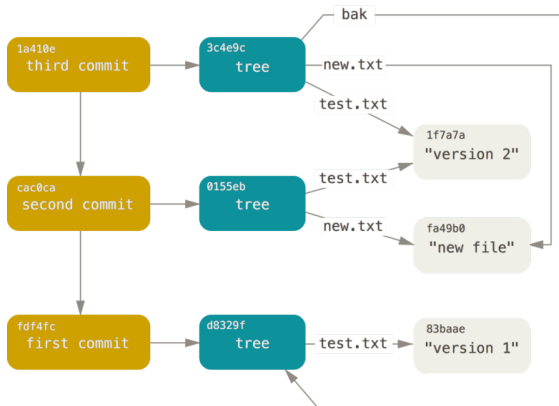
```
$ echo 'first commit' | git commit-tree d8329f  
fdf4fc3344e67ab068f836878b6c4951e3b15f3d
```

```
$ git cat-file -p fdf4fc3  
tree d8329fc1cc938780ffdd9f94e0d364e0ea74f579  
author Scott Chacon <schacon@gmail.com> 1243040974 -0700  
committer Scott Chacon <schacon@gmail.com> 1243040974 -0700
```

first commit

Ещё коммит хранит список коммитов-родителей

Коммиты, как это выглядит



Ссылки

Теперь вся информация хранится на диске, но чтобы ей воспользоваться, нужно помнить SHA-1 хеши. На помощь приходят reference-ы.

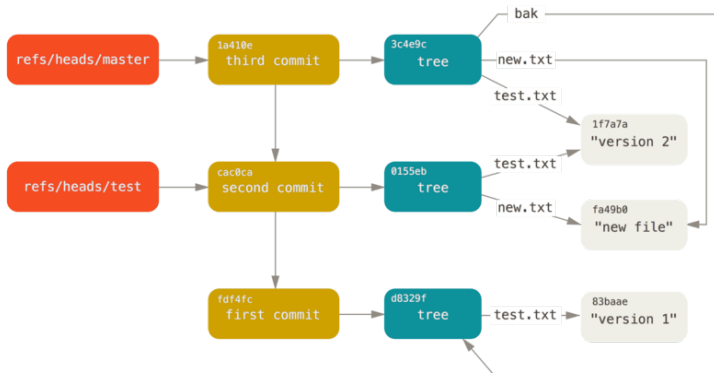
- ▶ `.git/refs`
- ▶ `.git/refs/heads`
- ▶ `.git/refs/tags`

```
$ echo "1a410efbd13591db07496601ebc7a059dd55cfe9" \  
> .git/refs/heads/master
```

```
$ git log --pretty=oneline master  
1a410efbd13591db07496601ebc7a059dd55cfe9 third commit  
cac0cab538b970a37ea1e769cbbde608743bc96d second commit  
fdf4fc3344e67ab068f836878b6c4951e3b15f3d first commit
```

- ▶ Команда `git update-ref`

Ссылки, как это выглядит



HEAD

Теперь не надо помнить хеши, но как переключаться между ветками?

Текущая ветка хранится в HEAD. HEAD — символическая ссылка, то есть ссылка на другую ссылку.

```
$ cat .git/HEAD  
ref: refs/heads/master
```

```
$ git symbolic-ref HEAD refs/heads/test  
$ cat .git/HEAD  
ref: refs/heads/test
```

Последний из объектов в Git — tag. Это просто указатель на КОММИТ.

- ▶ Легковесный тэг:

```
git update-ref refs/tags/v1.0 cac0cab538b970a37ea1e769cbbde608743bc96d
```

Или просто `git tag`

- ▶ Аннотированный тэг:

```
$ git tag -a v1.1 1a410efbd13591db07496601ebc7a059dd55cfe9 -m 'test tag'
```

```
$ git cat-file -p 9585191f37f7b0fb9444f35a9bf50de191beadc2
```

```
object 1a410efbd13591db07496601ebc7a059dd55cfe9
```

```
type commit
```

```
tag v1.1
```

```
tagger Scott Chacon <schacon@gmail.com> Sat May 23 16:48:58 2009 -0700
```

```
test tag
```

Packfiles

Пока что получалось, что все версии всех файлов в Git хранятся целиком, как они есть. Все они всегда сжимаются zlib, но в целом, если создать репозиторий, добавлять туда файлы, коммитить и т.д., все версии всех файлов будут в нём целиком. На помощь приходят .pack-файлы:

```
$ git gc
```

```
Counting objects: 18, done.
```

```
Delta compression using up to 8 threads.
```

```
Compressing objects: 100% (14/14), done.
```

```
Writing objects: 100% (18/18), done.
```

```
Total 18 (delta 3), reused 0 (delta 0)
```

```
$ find .git/objects -type f
```

```
.git/objects/bd/9dbf5aae1a3862dd1526723246b20206e5fc37
```


```
.git/objects/d6/70460b4b4aece5915caf5c68d12f560a9fe3e4
```

```
.git/objects/info/packs
```

```
.git/objects/pack/pack-978e03944f5c581011e6998cd0e9e30000905586.idx
```

```
.git/objects/pack/pack-978e03944f5c581011e6998cd0e9e30000905586.pack
```


Как оно устроено



Раск-файлы, подробности

- ▶ Упаковка происходит, когда:
 - ▶ Выполняется `git push`
 - ▶ Слишком много «свободных» объектов (порядка 7000)
 - ▶ Вручную вызвана `git gc`
- ▶ Используется дельта-компрессия
 - ▶ Последняя версия хранится целиком, дельты «идут назад»
- ▶ Можно заглянуть внутрь, `git verify-pack`
- ▶ Git может хитро перепаковать раск-файлы

Reflog и восстановление коммитов

```
$ git reflog
```

```
1a410ef HEAD@{0}: reset: moving to 1a410ef
```

```
ab1afef HEAD@{1}: commit: modified repo.rb a bit
```

```
484a592 HEAD@{2}: commit: added repo.rb
```

```
$ git log -g
```

```
commit 1a410efbd13591db07496601ebc7a059dd55cfe9
```

```
Reflog: HEAD@{0} (Scott Chacon <schacon@gmail.com>)
```

```
Reflog message: updating HEAD
```

```
Author: Scott Chacon <schacon@gmail.com>
```

```
Date: Fri May 22 18:22:37 2009 -0700
```

```
third commit
```

```
$ git branch recover-branch ab1afef
```

Как более капитально прострелить себе ногу

И что делать

```
$ git branch -D recover-branch
```

```
$ rm -Rf .git/logs/
```

```
$ git fsck --full
```

```
Checking object directories: 100% (256/256), done.
```

```
Checking objects: 100% (18/18), done.
```

```
dangling blob d670460b4b4aece5915caf5c68d12f560a9fe3e4
```

```
dangling commit ab1afef80fac8e34258ff41fc1b867c702daa24b
```

```
dangling tree aea790b9a58f6cf6f2804eeac9f0abbe9631e4c9
```

```
dangling blob 7108f7ecb345ee9d0084193f147cdad4d2998293
```

Git не удалит даже «висячие» объекты несколько месяцев, если его явно не попросить.

Lessons Learned

- ▶ Команды реализовывались как набор шелл-скриптов
 - ▶ Не портировать под Windows
 - ▶ Сложно интегрировать с IDE
 - ▶ Замедлило внедрение git-a
- ▶ Большой набор команд (включая plumbing) делает Git тяжёлым для изучения и усложняет сообщения об ошибках

- ▶ Python + C
- ▶ Распределённая VCS
- ▶ Architectural drivers
 - ▶ Масштабные open-source-проекты (ядро Linux)
 - ▶ Миллионы файлов
 - ▶ Миллионы ревизий
 - ▶ Тысячи пользователей, вносящих изменения параллельно в течение десятилетий
 - ▶ Компрессия хранилища данных
 - ▶ Эффективное получение произвольных ревизий
 - ▶ Эффективное добавление новых ревизий
 - ▶ Работа с историями файлов

²По <http://aosabook.org>

- ▶ Каждый файл хранится в виде набора ревизий
- ▶ Ревизии хранятся в виде дельт, иногда снапшоты файла целиком
- ▶ Каждая ревизия описывается записью с форматом как на рисунке
- ▶ Отдельно файл с дельтами (данные), отдельно файл с записями (индекс)
- ▶ Сжатие zlib

6 bytes	hunk offset
2 bytes	flags
4 bytes	hunk length
4 bytes	uncompressed length
4 bytes	base revision
4 bytes	link revision
4 bytes	parent 1 revision
4 bytes	parent 2 revision
32 bytes	hash

Структура revlog-ов

- ▶ Changelog — метаданные о ревизии + ссылка на манифест
- ▶ Manifests — список имён файлов в ревизии + для каждого ссылка на filelog
- ▶ Filelog — содержимое файлов ревизии + немного метаданных
- ▶ Dirstate — информация о рабочей копии, кеш дерева файлов
- ▶ Обновление логов в фиксированном порядке, гарантирующее консистентность
- ▶ Revlog-и хранятся тоже в виде дельт



Как это выглядит

Changelog:

0a773e3480fe58d62dcc67bd9f7380d6403e26fa

Dirkjan Ochtman <dirkjan@ochtman.nl>

1276097267 -7200

mercurial/discovery.py

discovery: fix description line

Manifest:

.hgignore\x006d2dc16e96ab48b2fcca44f7e9f4b8c3289cb701


.hgsigs\x00de81f258b33189c609d299fd605e6c72182d7359

.hgtags\x00b174a4a4813ddd89c1d2f88878e05acc58263efa

CONTRIBUTORS\x007c8afb9501740a450c549b4b1f002c803c4519

COPYING\x005ac863e17c7035f1d11828d848fb2ca450d89794

Ревизии




© <https://www.mercurial-scm.org/wiki/UnderstandingMercurial>

- ▶ Локальный номер ревизии
 - ▶ Доступ за константное время к узлу в revlog-е
- ▶ Глобальный SHA-1-хеш ревизии

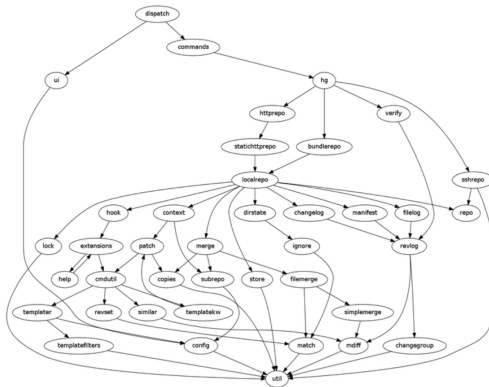
Ветки

1. Создание ветки через клонирование репозитория
 2. Bookmarks — объекты-ссылки в духе git
 3. Именованные ветки — имя ветки в метаданных ревизии
 4. Анонимные ветки
- Тэги хранятся как версиируемый файл .hgtags в репозитории



Статическая структура

- ▶ Один модуль — один файл
- ▶ CLI
- ▶ Одна команда — одна функция, все в одном файле
- ▶ Хеш-таблица, отображающая имена команд на функции
- ▶ Опции, общие наборы опций



Расширяемость

- ▶ Модули расширения
 - ▶ Новые команды
 - ▶ cmdtable, uisetup, reposetup
 - ▶ Обёртки над существующими командами
 - ▶ Обёртки над репозиторием
 - ▶ Обёртки над любой функцией Mercurial
 - ▶ Новые типы репозитория (например, hgsubversion)
 - ▶ Алиасы
- ▶ hooks
 - ▶ Вызов шелл-скрипта
 - ▶ Вызов Python-функции

Lessons Learned

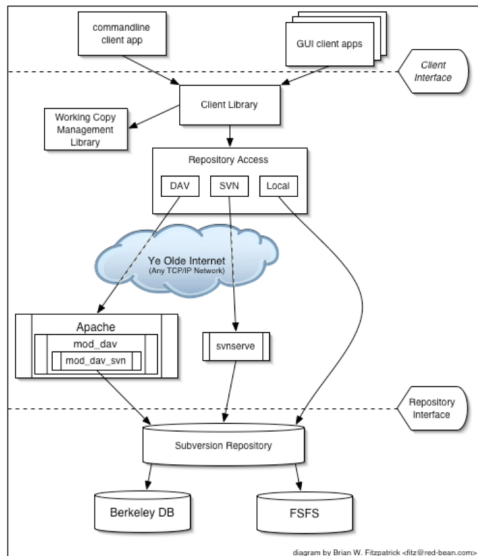
- ▶ Python: и хорошо, и плохо
- ▶ Намеренно сложно модифицировать changeset после публикации, что плохо для локальной работы
- ▶ Revlogs + модель данных – хорошо и эффективно, но не дружат с переименованиями
- ▶ Небольшое количество основных команд помогает легче научиться
- ▶ .hgtags оказался внезапен для пользователей
- ▶ Люди впервые познакомились с Python, чтобы писать расширения для mercurial, потому что это просто

Subversion³

- ▶ Написана на C
- ▶ Централизованная VCS
- ▶ Architectural drivers
 - ▶ починить CVS
 - ▶ не поддерживать обратную совместимость с CVS, но сделать переход по возможности безболезненным
 - ▶ развивать проект как open source

³ По <http://svnbook.red-bean.com/en/1.7/svn-book.html>

Архитектура



Ревизии и репозиторий

- ▶ Ревизии имеют уникальный числовой номер
 - ▶ Хранятся в виде обратных дельт со снапшотами
- ▶ Номер ревизии — свойство всего репозитория, а не файла
- ▶ В рабочей копии ревизии разных файлов могут быть разными
- ▶ Коммиты атомарны
- ▶ Единое дерево исходников
 - ▶ trunk
 - ▶ branches
 - ▶ tags
- ▶ Ветка и тэг — не более чем копия папки
- ▶ Репозиторий не хранит копии одного файла
- ▶ Можно чекаутить конкретную папку

Структура репозитория

- ▶ `conf/` — папка с конфигурационными файлами
- ▶ `db/` — хранилище версионированных данных
 - ▶ BerkleyDB или FSFS
- ▶ `format` — описывает организацию репозитория
- ▶ `hooks/` — папка со скриптами-хуками
- ▶ `locks/` — замки для управления одновременным доступом
- ▶ `README.txt` — файл, в котором написано, что это репозиторий Subversion

Свойства

- ▶ Свойства — пары “ключ-значение”, которые хранятся вместе с файлами, папками или ревизиями
- ▶ Ключ — строка из ASCII-символов, значение — любой массив байтов
- ▶ Версионироваться как данные в самих файлах
- ▶ Активно используются самой Subversion и тулами
 - ▶ Например, `svn:ignore`, `svn:eol-style`
- ▶ Например, для набора изображений можно хранить в свойствах описание, дату и даже `thumbnail`

Проблемы и ограничения

- ▶ Переименование реализовано как `copy` и `delete`, что смущает разрешение конфликтов
- ▶ До версии 1.7 папки `.svn` хранились в каждой папке проекта
- ▶ При чекауте не выставляются “настоящие” времена модификации файлов, используется время чекаута
 - ▶ Неожиданно для пользователя, но полезно для `make`
- ▶ “Наивная” поддержка веток и тэгов, делает невозможными некоторые операции
 - ▶ Например, `svn log -r tag1:tag2 myfile`